

Análisis de Variables para la Predicción de Churn en KKBOX

1. Introducción

Este documento presenta el análisis completo de las variables utilizadas para la predicción de churn en el dataset de KKBOX. Se examinan las 36 variables predictivas y la variable objetivo, evaluando su importancia mediante tres metodologías independientes: Random Forest (Importancia Gini), Permutation Importance y ANOVA F-Test. El objetivo es identificar las variables con mayor capacidad predictiva y proponer acciones para optimizar el modelo, ya sea manteniéndose, eliminándolas o transformándose.

2. Variable Objetivo

Variable	Tipo	Descripción
is_churn	Binaria (0/1)	Indica si el usuario canceló el servicio. El valor 1 representa churn y 0 permanencia. La tasa de churn observada es de 8.99 %, por lo que el problema presenta desbalance de clases

3. Metodología de Machine Learning

Con el objetivo de identificar los factores que influyen en la cancelación de suscripciones (churn) en KKBOX, se implementó un pipeline de aprendizaje automático compuesto por cuatro etapas principales:

Preprocesamiento de datos

Los datos fueron integrados a partir de cuatro fuentes principales:

- members_v3.csv
- transactions_v2.csv
- user_logs_v2.csv
- train_v2.csv

Posteriormente se realizó:

- limpieza de valores faltantes;
- transformación de fechas;
- agregación por usuario (msno);
- construcción de variables derivadas;
- eliminación de variables con alta cantidad de datos faltantes o baja calidad.

Como resultado se obtuvo un conjunto de 970,960 usuarios con 36 variables predictoras, además de la variable objetivo is_churn, que presenta una tasa de abandono del 8.99 %, evidenciando un problema de clasificación desbalanceado.

Modelos y técnicas utilizadas

Random Forest Feature Importance

Fue el principal modelo utilizado para estimar la importancia de las variables. Se eligió debido a que:

- captura relaciones no lineales;
- maneja adecuadamente variables numéricas y categóricas;
- es robusto frente a ruido y multicolinealidad moderada;
- permite obtener la importancia de cada característica mediante la reducción del índice Gini.

El modelo final fue entrenado con:

- 100 árboles
- profundidad máxima de 15 niveles
- mínimo de 10 muestras por hoja
- `random_state = 42`
- `class_weight` para compensar el desbalance de clases.

Permutation Importance

Posteriormente se aplicó Permutation Importance para validar los resultados obtenidos con Random Forest. Esta técnica mide cuánto disminuye el desempeño del modelo cuando una variable es permutada aleatoriamente. Las variables cuya permutación provoca la mayor caída en precisión son consideradas las más relevantes. Esta metodología permitió confirmar que las variables temporales dominan el comportamiento predictivo del modelo.

ANOVA F-Test

Como tercer método independiente se utilizó SelectKBest con ANOVA F-Test. Este método estadístico evalúa si existen diferencias significativas entre las distribuciones de cada variable respecto a la variable objetivo. Aunque ANOVA sólo considera relaciones lineales, permitió validar estadísticamente los resultados obtenidos mediante Random Forest y Permutation Importance.

Selección de variables

Finalmente, la selección de variables se realizó considerando simultáneamente:

- Importancia obtenida mediante Random Forest.
- Resultados de Permutation Importance.
- ANOVA F-Test.
- Análisis de multicolinealidad mediante la matriz de correlación de Pearson.

Únicamente se conservaron las variables que aportan información independiente al modelo y se eliminaron aquellas altamente correlacionadas entre sí para evitar redundancia e incrementar la interpretabilidad del modelo.

4. Variables Demográficas

Las variables demográficas provienen del archivo members_v3.csv y describen características generales del usuario.

- **city:** Corresponde al código de ciudad del usuario, con valores aproximados entre 1 y 22. Aunque obtuvo un F-score considerable en ANOVA (777), su importancia relativa fue baja en Random Forest y Permutation Importance, por lo que se decidió excluirla del modelo final.
- **registered_via:** Representa el canal mediante el cual el usuario se registró en la plataforma. El análisis mostró diferencias importantes entre canales (el canal 4 presentó una tasa de churn del 23.1%, mientras que el canal 7 alcanzó el 4.6%). A pesar de su importancia predictiva moderada, resulta una variable valiosa para la segmentación y toma de decisiones de negocio.
- **age:** Variable eliminada. Se derivó a partir del campo bd (fecha de nacimiento), pero más del 60% de los registros presentaban valores inválidos o faltantes, afectando severamente su calidad.
- **gender:** Variable eliminada. Solo el 40% de los usuarios contaba con información de género, por lo que se descartó debido a la gran cantidad de valores faltantes.
- **days_since_registration:** Variable eliminada. La columna original registration_init_time presentó errores de conversión a formato fecha, provocando valores nulos en la totalidad de los registros.

5. Variables de Transacciones

Las variables de esta sección fueron generadas a partir del archivo transactions_v2.csv, agregando la información por usuario (msno).

5.1 membership_duration_days

Es la variable más importante del modelo. Mide la cantidad de días transcurridos entre la última transacción y la fecha de expiración más reciente de la membresía. Esta variable concentra aproximadamente el 18.2% de la importancia total del Random Forest, siendo 3.2 veces más importante que la segunda variable del ranking. Desde la perspectiva del negocio, refleja la antigüedad y estabilidad del usuario dentro de la plataforma, convirtiéndose en el principal indicador de retención.

Estadísticas principales: Media: 39.3 días | Mediana: 31 días | Máximo: 2,575 días | Mínimo: -3 días (inconsistencia en datos)

5.2 days_since_last_txn

Mide el número de días transcurridos desde la última transacción del usuario. Es una de las variables temporales más relevantes y tiene una relación directa con la probabilidad de churn: cuanto mayor sea el tiempo sin transacciones, mayor será el riesgo de abandono. Se observó un pico importante alrededor de los 30 días, coincidiendo con el ciclo mensual de facturación.

5.3 days_since_last_expire

Representa los días transcurridos desde la última expiración de la membresía. Junto con membership_duration_days y days_since_last_txn, conforma el grupo de variables temporales más influyente del modelo. Sin embargo, presenta algunos valores negativos extremos que sugieren inconsistencias y requieren limpieza previa.

5.4 payment_method_mode

Corresponde al método de pago más frecuente utilizado por el usuario. El análisis reveló un hallazgo importante: cinco métodos de pago específicos presentan tasas cercanas al 100% de churn. Esto sugiere la existencia de usuarios asociados a pruebas gratuitas, métodos obsoletos o posibles casos atípicos. Además de su capacidad predictiva, esta variable tiene gran utilidad para la segmentación de clientes.

5.5 actual_amount_paid_sum

Representa la suma total de dinero pagado por cada usuario. Es una medida del valor económico acumulado y combina tanto la frecuencia como el monto de los pagos realizados. Se detectaron valores extremos considerables, por lo que se recomienda aplicar una transformación logarítmica (log1p) para reducir la asimetría de la distribución.


6. Variables de Actividad y Uso

Estas variables fueron obtenidas a partir del archivo user_logs_v2.csv y resumen el comportamiento de escucha de cada usuario.

- **days_since_last_log:** Indica cuántos días han pasado desde la última actividad registrada. Es la variable de comportamiento más importante. El análisis mostró que los usuarios con más de 60 días sin actividad presentan una tasa de churn cercana al 26.6%, aproximadamente tres veces superior al promedio general. Esto la convierte en una excelente candidata para implementar sistemas de alerta temprana.
- **log_count:** Representa la cantidad total de registros de actividad del usuario. Aunque su importancia individual es moderada, presenta una relación inversa y consistente con el churn: más actividad implica menor probabilidad de abandono, y menor actividad implica mayor probabilidad de abandono. Esta estabilidad la convierte en una variable especialmente útil para interpretar el comportamiento del usuario.

7. Justificación de Variables Basada en la Matriz de Correlación

Además de los métodos de selección de características, se realizó un análisis de la matriz de correlación de Pearson con el objetivo de detectar problemas de multicolinealidad entre las 36 variables predictoras. La matriz permitió identificar grupos de variables que contenían prácticamente la misma información, así como variables altamente correlacionadas de forma negativa que, aunque relacionadas, describen fenómenos distintos y por lo tanto aportan información complementaria al modelo.



Bloque 1. Variables financieras

Se identificó un primer bloque de alta correlación conformado por las variables relacionadas con precios y montos pagados. Las correlaciones más importantes fueron:

- $\text{plan_list_price_mean} \leftrightarrow \text{actual_amount_paid_mean}$ (0.999)
- $\text{plan_list_price_max} \leftrightarrow \text{actual_amount_paid_max}$ (0.999)
- $\text{plan_list_price_mean} \leftrightarrow \text{plan_list_price_max}$ (0.977)

Estas correlaciones prácticamente perfectas indican que las variables contienen información redundante. Por esta razón únicamente se conservó `plan_list_price_mean`, eliminando:

- `actual_amount_paid_mean`
- `actual_amount_paid_max`
- `plan_list_price_max`

Con ello se redujo la redundancia del modelo sin perder capacidad predictiva.

Bloque 2. Duración del plan

La matriz mostró una correlación de 0.979 entre `payment_plan_days_mean` y `payment_plan_days_max`. Debido a que ambas describen prácticamente el mismo comportamiento del usuario, únicamente se conservó `payment_plan_days_mean`, descartando la versión máxima.

Bloque 3. Variables de actividad

Las variables derivadas de los registros de escucha presentaron uno de los mayores niveles de multicolinealidad del conjunto de datos. Se identificaron correlaciones superiores al 0.98 entre:

- `num_100_sum` y `total_secs_sum`
- `num_100_mean` y `total_secs_mean`
- `total_secs_mean` y `total_secs_sum`

Esto indica que todas estas variables describen esencialmente la misma intensidad de uso de la plataforma. Por ello se decidió conservar únicamente las variables representativas y eliminar las variables medias, desviaciones estándar y aquellas cuya información ya estaba contenida en otras variables equivalentes.

Correlaciones negativas

La matriz también mostró correlaciones negativas importantes que no implican redundancia:

- **`membership_duration_days` vs `days_since_last_expire` ($r = -0.91$):** Aunque presentan una correlación muy elevada, ambas variables representan conceptos diferentes. `membership_duration_days` mide la antigüedad acumulada del cliente, mientras que `days_since_last_expire` mide cuánto tiempo ha permanecido sin una membresía activa. Por ello ambas fueron conservadas, ya que aportan información complementaria.
- **`days_since_last_expire` vs `plan_list_price_mean` ($r \approx -0.67$):** Indica que los usuarios con mayor tiempo desde la expiración suelen estar asociados a planes de menor costo. Esta relación resulta útil para identificar segmentos de riesgo y fue mantenida dentro del modelo.

- **is_auto_renew_rate vs plan_list_price_mean (\$r = -0.40\$):** Indica que los usuarios sin renovación automática tienden a contratar planes de mayor precio. Esta información complementa el comportamiento financiero del usuario y mejora la capacidad predictiva del modelo.

Variables independientes

Finalmente, la matriz evidenció varias variables con baja correlación respecto al resto del conjunto. Entre ellas destacan:

- payment_method_mode
- is_cancel_rate
- days_since_last_log
- log_count

Estas variables aportan información ortogonal al modelo, relacionada con comportamiento de pago, historial de cancelaciones y actividad del usuario, por lo que fueron conservadas en la versión final.

Variables finales seleccionadas

Como resultado del análisis conjunto entre importancia predictiva y matriz de correlación, el modelo conservó principalmente las siguientes variables:

Variable	Justificación
membership_duration_days	Principal indicador de permanencia del usuario.
days_since_last_txn	Refleja el tiempo desde la última transacción realizada.
days_since_last_expire	Complementa la información temporal sin ser redundante.
payment_method_mode	Captura patrones asociados al método de pago.
actual_amount_paid_sum	Resume el valor económico acumulado del usuario.
is_cancel_rate	Historial de cancelaciones con alta capacidad predictiva.
plan_list_price_mean	Representante del bloque financiero tras eliminar variables redundantes.
days_since_last_log	Principal indicador de inactividad del usuario.
log_count	Resume la frecuencia de uso de la plataforma.
is_auto_renew_rate	Aporta información sobre hábitos de renovación de la membresía.

8. Top 10 Variables Más Importantes

El siguiente ranking consolida los resultados obtenidos mediante Random Forest, Permutation Importance y ANOVA.

Posición	Variable	Justificación
1	membership_duration_days	Variable dominante del modelo.
2	days_since_last_txn	Predictor temporal con gran impacto.
3	days_since_last_expire	Complementa la información temporal del usuario.
4	payment_method_mode	Alta capacidad de segmentación.
5	actual_amount_paid_sum	Representa el valor económico acumulado.
6	is_cancel_rate	Captura el historial de cancelaciones.
7	plan_list_price_mean	Resume el comportamiento de precios.
8	days_since_last_log	Principal indicador de inactividad.
9	log_count	Relación inversa estable con churn.
10	is_auto_renew_rate	Aporta información sobre hábitos de renovación de la membresía.

9. Recomendaciones

Variables a mantener

Se recomienda conservar las variables con mayor poder predictivo :

- membership_duration_days
- days_since_last_txn
- days_since_last_expire
- payment_method_mode
- actual_amount_paid_sum
- is_cancel_rate
- plan_list_price_mean
- days_since_last_log
- log_count
- is_auto_renew_rate

Variables a eliminar

Las siguientes variables presentan multicolinealidad o aportan poca información :

- actual_amount_paid_max
- actual_amount_paid_mean
- plan_list_price_max
- payment_plan_days_max
- num_25_mean
- num_50_mean
- num_75_mean
- num_985_mean
- num_100_mean
- num_unq_mean
- total_secs_std

Variables a transformar

Para mejorar la calidad del modelo, se recomienda :

- Aplicar $\log(1 + x)$ a:
 - actual_amount_paid_sum
 - total_secs_sum
 - txn_count
- Aplicar Winsorización a days_since_last_txn.
- Filtrar valores inconsistentes como days_since_last_expire menores a -365.

10. Conclusión

El análisis integró tres metodologías de selección de características (Random Forest Feature Importance, Permutation Importance y ANOVA F-Test), complementadas con un estudio de multicolinealidad mediante la matriz de correlación de Pearson. Este enfoque permitió identificar las variables con mayor capacidad predictiva y eliminar aquellas que aportaban información redundante. Se comprobó que las variables temporales asociadas a la membresía (membership_duration_days, days_since_last_txn y days_since_last_expire) constituyen los principales predictores del churn, mientras que las variables financieras y de comportamiento complementan el modelo con información relevante sobre el valor económico y la actividad del usuario. Finalmente, la reducción de variables redundantes permitió simplificar el conjunto de características, mejorar la interpretabilidad del modelo y mantener su capacidad predictiva, proporcionando una base sólida para implementar estrategias de retención y sistemas de alerta temprana en KKBOX.