

Documento de Análisis del Modelo de Predicción de Churn (KKBOX)

Documento de Análisis del Modelo de Predicción de Churn (KKBOX)	1
1. Descripción del proyecto	2
Pregunta de negocio	2
¿Qué hace el sistema?	2
Variable objetivo	3
2. Resumen ejecutivo	3
3. Descripción del modelo	4
3.1 ¿Qué es el modelo?	4
3.2 Entradas y salidas del modelo	4
Entrada	4
Salida	4
3.3 Hiperparámetros	5
3.4 Construcción y funcionamiento	5
4. Metodología de las pruebas	6
5. Resultados de las pruebas	6
Advertencias detectadas	6
6. Análisis de las gráficas	7
6.1 Distribución de probabilidades de churn	7
Explicación	7
Interpretación	8
6.2 Distribución de usuarios por grupo de riesgo	8
Explicación	9
Interpretación	9
6.3 Curva de umbrales de decisión	9
Explicación	10
Interpretación	10
6.4 Importancia de características (Gini)	10
Explicación	11
Interpretación	11
6.5 Curvas de sensibilidad de las características principales	12
Explicación	12
Interpretación	12
6.6 Incertidumbre del modelo (desviación entre árboles)	12
Explicación	13
Interpretación	13
6.7 Ranking de impacto de características	13
Explicación	14

Interpretación	15
7. Justificación de la eficiencia del modelo	15
1. Rapidez de carga y predicción	15
2. Robustez numérica	15
3. Capacidad discriminativa	16
4. Interpretabilidad	16
5. Manejo del desbalance de clases	16
Limitaciones del modelo	17
Calibración de probabilidades	17
Incertidumbre entre árboles	17
Validación con datos reales	17
8. Conclusiones y recomendaciones	18
Repositorio git	18
Anexo A. Correspondencia de imágenes	18
Anexo B. Archivos generados por las pruebas	19

1. Descripción del proyecto

Este proyecto consiste en un **sistema de predicción de abandono de usuarios (Churn Prediction)** para una plataforma de streaming de música. Su objetivo principal es determinar qué usuarios tienen mayor probabilidad de dejar de utilizar el servicio, utilizando información relacionada con su comportamiento de pago y actividad dentro de la plataforma.

Pregunta de negocio

¿Qué usuarios están en riesgo de abandonar la plataforma para poder aplicar campañas de retención antes de que cancelen su suscripción?

¿Qué hace el sistema?

El sistema está compuesto por tres etapas principales:

1. Entrenamiento del modelo

- El archivo `src/analisis_kkbox.py` construye un modelo de Random Forest utilizando el conjunto de datos público de KKBOX.

- Se emplean datos de transacciones, membresías y actividad de los usuarios.
2. **Despliegue del modelo**
- El modelo entrenado se almacena como `output/rf_churn_model.pkl`.
 - Posteriormente es cargado mediante `src/modelo.py` y utilizado por la aplicación web (`web_app/app.py`).
3. **Pruebas y análisis**
- El archivo `src/Pruebas.py` ejecuta diferentes pruebas para validar el funcionamiento del modelo.
 - Además genera las gráficas utilizadas en este documento.

Variable objetivo

La variable objetivo es:

`is_churn`

- **1** → El usuario abandonó la plataforma.
- **0** → El usuario continúa activo.

El modelo calcula la probabilidad de que un usuario pertenezca al grupo que abandonará el servicio, permitiendo clasificarlo como riesgo **bajo**, **medio** o **alto**.

2. Resumen ejecutivo

El modelo `output/rf_churn_model.pkl` corresponde a un **Random Forest Classifier**, diseñado para predecir si un usuario abandonará la plataforma de música KKBOX.

Durante las pruebas realizadas:

- El modelo fue deserializado correctamente mediante `joblib`.
- Se ejecutaron **18 pruebas automáticas**.
- Los resultados obtenidos fueron:

Resultado o	Cantidad
PASS	14
WARN	4
FAIL	0

Las pruebas permitieron analizar tres aspectos principales:

- **Comportamiento general del modelo**, observando cómo distribuye las probabilidades de abandono.

- **Interpretabilidad**, identificando las variables más importantes para realizar la predicción.
- **Robustez**, evaluando la estabilidad del modelo frente a ruido, incertidumbre y valores extremos.

3. Descripción del modelo

3.1 ¿Qué es el modelo?

El modelo utilizado es un **Random Forest Classifier** (Bosque Aleatorio), un algoritmo de aprendizaje supervisado que combina múltiples árboles de decisión independientes.

Cada árbol aprende utilizando una muestra diferente de datos y un subconjunto aleatorio de características. La predicción final se obtiene promediando las probabilidades calculadas por todos los árboles.

Este enfoque permite:

- Reducir el sobreajuste.
- Manejar adecuadamente variables correlacionadas.
- Obtener predicciones más robustas frente al ruido.

Debido a estas características, Random Forest resulta especialmente adecuado para analizar el comportamiento de los usuarios en plataformas digitales.

3.2 Entradas y salidas del modelo

Entrada

El modelo recibe **36 variables numéricas**, entre ellas:

- Historial de pagos.
- Información de membresías.
- Actividad de escucha.
- Datos demográficos del usuario.

Salida

El modelo devuelve:

- Una probabilidad entre **0 y 1** indicando la probabilidad de abandono.
- Una clasificación binaria:

Valor	Significado
0	Usuario continúa activo
1	Usuario abandona el servicio

3.3 Hiperparámetros

Parámetro	Valor
Modelo	RandomForestClassifier
Número de árboles	100
Profundidad máxima	15
Criterio	Gini
class_weight	balanced
max_features	sqrt
min_samples_leaf	10
random_state	42
Número de características	36

Estos parámetros ayudan a obtener un equilibrio entre precisión, estabilidad y capacidad de generalización del modelo.

3.4 Construcción y funcionamiento

El proceso seguido para construir el modelo fue:

1. Se procesaron los conjuntos de datos de KKBOX.
2. Se agruparon las métricas por usuario (`msno`).
3. Se imputaron valores faltantes.
4. Se entrenó un Random Forest utilizando validación cruzada.
5. Se aplicó `class_weight='balanced'` para compensar el desbalance entre usuarios que abandonan y los que permanecen.
6. El modelo entrenado se almacenó en `output/rf_churn_model.pkl`.

7. La aplicación web carga el modelo mediante `src/modelo.py`.
8. Finalmente, la aplicación clasifica cada usuario en tres niveles de riesgo:

Riesgo	Probabilidad
Bajo	Menor a 0.30
Medio	Entre 0.30 y 0.70
Alto	Mayor o igual a 0.70

4. Metodología de las pruebas

Como el conjunto de datos original no está incluido en el repositorio, las pruebas se realizaron utilizando una **población sintética reproducible** de **20 000 usuarios**, generada mediante una semilla (`seed`) igual a **42**.

Cada característica fue generada utilizando distribuciones normales truncadas centradas en los valores utilizados por la aplicación web, respetando rangos considerados plausibles.

Importante: La población sintética **no representa la población real de KKBOX**. Por ello, las métricas obtenidas deben interpretarse únicamente como un análisis del comportamiento y robustez del modelo, y no como estimaciones reales del porcentaje de usuarios que abandonarán la plataforma.

5. Resultados de las pruebas

Después de ejecutar todas las pruebas del modelo se obtuvieron los siguientes resultados:

Resultado	Cantidad
PASS	14
WARN	4
FAIL	0

Los cuatro resultados marcados como **WARN** no representan errores del modelo, sino observaciones importantes acerca de su comportamiento.

Advertencias detectadas

T10 – 95.5 % de churn utilizando un umbral de 0.5

El modelo concentra gran parte de sus predicciones en probabilidades altas de abandono. Esto indica un problema de calibración y no un fallo de funcionamiento.

T15 y T16 – Umbrales de decisión

Para que únicamente el **10 %** de la población sea clasificada como abandono, el umbral debe elevarse aproximadamente hasta **0.79**.

Para clasificar solamente el **20 %** de la población como abandono, el umbral debe situarse cerca de **0.75**.


T18 – Incertidumbre entre árboles

La desviación promedio entre los 100 árboles del bosque fue de **0.375**, indicando que existe una dispersión considerable entre las predicciones individuales de cada árbol.

6. Análisis de las gráficas

6.1 Distribución de probabilidades de churn

Imagen



Explicación

Esta gráfica representa la distribución de las probabilidades de abandono calculadas por el modelo para toda la población sintética.

Además incluye líneas de referencia correspondientes a los umbrales de:

- Riesgo bajo
- Riesgo medio

- Riesgo alto
- Promedio de las probabilidades

Interpretación

La mayor parte de las probabilidades se concentra aproximadamente entre **0.60 y 0.95**.


Muy pocos usuarios obtienen probabilidades inferiores a **0.30**, lo que indica que el modelo tiende a asignar probabilidades elevadas de abandono.

Este comportamiento sugiere que el modelo sobreestima el riesgo de churn y comprime las predicciones dentro de un rango relativamente pequeño.

Por esta razón sería recomendable recalibrar las probabilidades utilizando técnicas como **CalibratedClassifierCV** o ajustar los umbrales antes de utilizar el modelo en producción.

6.2 Distribución de usuarios por grupo de riesgo

Imagen



Explicación

Los usuarios son clasificados según los criterios utilizados por la aplicación web:

Nivel	Probabilidad
Bajo	Menor de 0.30
Medio	Entre 0.30 y 0.70
Alto	Mayor o igual a 0.70

Interpretación


La población sintética quedó distribuida aproximadamente de la siguiente manera:

Riesgo	Porcentaje
Bajo	0.06 %
Medio	62.1 %
Alto	37.8 %

Puede observarse que prácticamente ningún usuario fue clasificado como riesgo bajo.

Esto confirma que el modelo produce probabilidades elevadas para la mayoría de los usuarios, por lo que sería conveniente recalcular los umbrales utilizando datos reales.

6.3 Curva de umbrales de decisión



Explicación

La gráfica muestra el porcentaje de usuarios que serían clasificados como abandono al modificar el umbral de decisión entre **0** y **1**.

Interpretación

La curva disminuye lentamente conforme aumenta el umbral.

Esto significa que es necesario utilizar umbrales bastante altos para reducir la cantidad de usuarios clasificados como churn.


Por ejemplo:

- Umbral **0.79** → aproximadamente el 10 % de los usuarios sería clasificado como abandono.
- Umbral **0.75** → aproximadamente el 20 % de los usuarios sería clasificado como abandono.

Esta información resulta útil para seleccionar el punto de corte más conveniente dependiendo del costo asociado a falsos positivos y falsos negativos.

6.4 Importancia de características (Gini)

Imagen



Explicación

Esta gráfica presenta la importancia promedio de cada característica calculada mediante el índice de Gini utilizado por el Random Forest.

Interpretación

Las variables más importantes fueron:


Variable	Importancia
membership_duration_days	19.2 %
days_since_last_expire	13.9 %
actual_amount_paid_sum	11.3 %
days_since_last_txn	10.2 %
is_cancel_rate	6.6 %

Las cuatro primeras variables representan más del **54 %** de toda la importancia del modelo.

Esto demuestra que el historial de pagos y la duración de la membresía son los principales factores utilizados para predecir el abandono de usuarios.

Las variables relacionadas con la actividad de escucha aportan una menor influencia individual.

6.5 Curvas de sensibilidad de las características principales



Explicación

Cada subgráfica modifica una de las seis características más importantes mientras mantiene constantes las demás variables.

De esta manera es posible observar cómo cambia la probabilidad de abandono cuando varía únicamente una característica.

Interpretación

Las curvas permiten identificar relaciones no lineales entre las variables y la probabilidad de churn.


Por ejemplo:

- **days_since_last_expire**
- **days_since_last_txn**

presentan una disminución inicial de la probabilidad seguida por un incremento posterior.

Esto indica que tanto una expiración reciente como un largo periodo sin actividad pueden representar situaciones de riesgo.

6.6 Incertidumbre del modelo (desviación entre árboles)



Explicación

Esta gráfica muestra la desviación estándar de las predicciones generadas por los **100 árboles** que conforman el Random Forest.

Para una muestra de **3,000 usuarios**, se calcula la predicción individual de cada árbol y posteriormente se obtiene la desviación estándar promedio para distintos intervalos de probabilidad.

El objetivo es medir el nivel de acuerdo existente entre los árboles del bosque.

Interpretación


La incertidumbre promedio obtenida fue de **0.375**, lo que representa un valor relativamente alto.

Esto indica que los árboles no siempre coinciden completamente en sus predicciones.

Generalmente, los modelos Random Forest presentan una mayor incertidumbre cuando las probabilidades se encuentran cercanas a **0.50**, ya que existe mayor dificultad para decidir entre ambas clases.

Esta información resulta útil para determinar en qué regiones del modelo las predicciones son más confiables y dónde sería conveniente establecer los umbrales de clasificación.

6.7 Ranking de impacto de características



Explicación

A diferencia de la importancia de Gini, esta prueba mide cuánto puede modificar cada característica la probabilidad final de abandono.

Para ello se calcula el rango de variación:

Impacto = Probabilidad máxima – Probabilidad mínima

manteniendo constantes todas las demás variables.

Interpretación

Las variables con mayor impacto fueron:

Variable	Impacto
payment_method_mode	0.583
days_since_last_txn	0.468
days_since_last_expire	0.388
actual_amount_paid_sum	0.344

Este ranking es diferente al obtenido mediante la importancia de Gini.

Mientras la importancia de Gini mide qué variables son utilizadas con mayor frecuencia por el bosque durante el entrenamiento, el impacto representa cuánto puede cambiar la predicción al modificar únicamente una característica.

Ambos análisis se complementan y permiten identificar qué información resulta más relevante para comprender y mejorar el modelo.

7. Justificación de la eficiencia del modelo

El modelo demuestra un buen desempeño en diversos aspectos.

1. Rapidez de carga y predicción

El modelo está compuesto por **100 árboles de decisión** con una profundidad máxima de **15 niveles** y utiliza únicamente **36 características numéricas**.

Durante las pruebas fue capaz de realizar predicciones sobre **20,000 usuarios** en pocos segundos, por lo que resulta adecuado para aplicaciones web con respuestas en tiempo real.

2. Robustez numérica

Las pruebas mostraron que:

- Todas las probabilidades generadas permanecen dentro del intervalo **[0,1]**.
- Las predicciones son completamente deterministas; una misma entrada siempre produce el mismo resultado.
- El modelo mantiene estabilidad frente a pequeñas perturbaciones en los datos de entrada.

Esto demuestra que el algoritmo presenta un comportamiento consistente y confiable.

3. Capacidad discriminativa

Las curvas de sensibilidad evidencian que el modelo responde principalmente a las variables relacionadas con:

- Historial de pagos.
- Renovaciones.
- Tiempo desde la última actividad.
- Cancelaciones.

Estas variables coinciden con los factores que normalmente se relacionan con el abandono de usuarios en plataformas de suscripción.

4. Interpretabilidad

Una ventaja importante del Random Forest es que permite explicar fácilmente sus decisiones mediante:

- Importancia de características.
- Curvas de sensibilidad.
- Ranking de impacto.
- Distribución de probabilidades.

Esto facilita la interpretación de los resultados tanto para desarrolladores como para personal del área de negocio.

5. Manejo del desbalance de clases

El modelo fue entrenado utilizando:

```
class_weight = balanced
```

Con ello se evita favorecer únicamente a la clase mayoritaria, permitiendo detectar con mayor facilidad a los usuarios que realmente presentan riesgo de abandono.

Limitaciones del modelo

Aunque el modelo obtuvo resultados satisfactorios, aún presenta algunas limitaciones que deberían corregirse antes de utilizarlo en un entorno de producción.

Calibración de probabilidades

Las probabilidades se concentran en valores relativamente altos.

Como consecuencia, casi todos los usuarios terminan clasificados como riesgo medio o alto.

Sería recomendable recalibrar el modelo utilizando técnicas como **CalibratedClassifierCV** o realizar un nuevo entrenamiento.

Incertidumbre entre árboles

La desviación promedio de **0.375** indica que todavía existe una dispersión considerable entre los árboles del bosque.

Podría evaluarse:

- aumentar el número de árboles,
- modificar la profundidad,
- ajustar otros hiperparámetros.

Validación con datos reales

Todas las pruebas presentadas en este documento fueron realizadas utilizando una población sintética.

Para conocer el verdadero desempeño del modelo será necesario entrenarlo nuevamente utilizando el conjunto de datos real de KKBOX y calcular métricas como:

- ROC-AUC
- Accuracy
- Precision
- Recall
- F1-Score
- Matriz de confusión

8. Conclusiones y recomendaciones

Después de analizar los resultados obtenidos, pueden establecerse las siguientes conclusiones:

1. El modelo funciona correctamente y puede desplegarse sin problemas, ya que todas las pruebas finalizaron sin errores críticos.
2. El algoritmo identifica correctamente que las variables relacionadas con pagos y membresías son los factores más importantes para predecir el abandono de usuarios.
3. El Random Forest ofrece una buena capacidad de interpretación gracias a las gráficas de importancia, sensibilidad e impacto de las características.
4. Antes de utilizar el modelo en producción es recomendable:
 - recalibrar las probabilidades de salida;
 - ajustar los umbrales de clasificación utilizados por la aplicación web;
 - entrenar nuevamente utilizando el conjunto de datos original para obtener métricas reales de desempeño.

En términos generales, el modelo constituye una base sólida para desarrollar un sistema de predicción de abandono de clientes, aunque requiere una fase adicional de calibración y validación antes de ser utilizado en un entorno de producción.

[Repositorio](#) git

Anexo A. Correspondencia de imágenes

Sección	Archivo generado
6.1 Distribución de probabilidades	prueba_01_distribucion_probabilidades.png
6.2 Riesgo por grupo	prueba_02_riesgo_por_grupo.png
6.3 Curva de umbral	prueba_03_curva_umbral.png
6.4 Importancia de variables	prueba_04_importancia_features.png
6.5 Sensibilidad de variables	prueba_05_sensibilidad_features.png
6.6 Incertidumbre	prueba_06_incertidumbre.png

Anexo B. Archivos generados por las pruebas

Archivo	Descripción
output/pruebas_resumen.csv	Resultado de las 18 pruebas automáticas
output/prueba_metricas.json	Métricas completas del modelo
src/modelo.py	Clase encargada de cargar y utilizar el modelo entrenado
src/Pruebas.py	Script que ejecuta las pruebas y genera todas las gráficas