


Análisis de Variables para Predicción de Churn




Evaluación exhaustiva de 36 variables predictivas en KKBOX utilizando Random Forest, Permutation Importance y ANOVA F-Test para optimizar la retención de usuarios.



Contexto y Variable Objetivo

Entendiendo el desbalance de clases y la estructura del dataset.



La Variable Objetivo: is_churn

8.99%

Tasa de Churn Global

Clasificación Binaria Desbalanceada

Definición: Indicador binario (0/1) donde 1 representa cancelación de servicio y 0 permanencia.

Reto analítico: Al tratarse de un problema con marcada asimetría de clases (~9% abandono), se requirió la aplicación de métricas robustas y ponderación de clases en los modelos de Machine Learning.

Metodología de Validación



Random Forest

Modelo principal con 100 árboles y profundidad máxima de 15. Permite capturar no-linearidades y evaluar la reducción del índice Gini.



Permutation Importance

Técnica de validación que mide la caída exacta del rendimiento al permutar aleatoriamente cada variable, confirmando el peso temporal.



ANOVA F-Test

SelectKBest estadístico para comprobar la relación lineal de cada atributo frente al objetivo y respaldar los hallazgos del árbol.

Variables Demográficas y Limpieza

- ✓ **registered_via (Canal de Registro):** Muestra diferencias notables en la retención. El canal 4 presenta una tasa de churn del 23.1%, mientras que el canal 7 registra un 4.6%. Es vital para la segmentación comercial.
- ✗ **age (Edad):** Descartada debido a que más del 60% de los registros presentaban datos inválidos o faltantes derivados del campo de fecha de nacimiento.
- ✗ **gender (Género):** Eliminada del modelo final ya que solo el 40% de los usuarios contaba con esta información registrada.
- ✗ **days_since_registration:** Excluida por errores masivos de conversión en la fecha inicial de registro que dejaban nula la totalidad de la columna.

Variables Clave de Transacciones

membership_duration_days

Es la variable más importante del modelo (**18.2% de importancia Gini**). Mide los días entre la última transacción y la expiración. Refleja la estabilidad y antigüedad del usuario.

days_since_last_txn & expire

Variables temporales críticas que aumentan drásticamente el riesgo de churn conforme pasa el tiempo sin renovación. Se detectaron picos alrededor de los 30 días (ciclo de facturación).

Comportamiento de Escucha y Uso

days_since_last_log

Principal indicador conductual de inactividad.

Usuarios con más de **60 días sin actividad** presentan una tasa de churn cercana al **26.6%** (3x el promedio general), ideal para alertas tempranas.


log_count

Muestra una relación inversa y altamente estable con la cancelación: mayor frecuencia de registros de actividad en la plataforma se traduce directamente en una menor probabilidad de abandono.

Análisis de Multicolinealidad

- ⚠ **Bloque Financiero:** Fuerte correlación (~ 0.99) entre *plan_list_price_mean* y *actual_amount_paid_mean*. Se eliminan redundancias conservando únicamente los precios base de los planes.
- ⚠ **Bloque de Actividad:** Las variables de reproducción total (*total_secs_sum* vs *num_100_sum*) presentaban multicolinealidad superior a 0.98, depurando los promedios y desviaciones innecesarias.
- 🔗 **Correlaciones Negativas Útiles:** Se mantuvo *membership_duration_days* frente a *days_since_last_expire* ($r = -0.91$) por medir dimensiones de negocio complementarias.

#	Variable	Impacto Principal en el Negocio
1	membership_duration_days	Variable dominante de retención y antigüedad
2	days_since_last_txn	Predictor temporal de estatus de pago
3	days_since_last_expire	Mide el riesgo crítico tras el vencimiento
4	payment_method_mode	Detecta métodos asociados a pruebas o fraude
5	actual_amount_paid_sum	Valor económico acumulado del suscriptor



Acciones y Recomendaciones Técnicas

Transformaciones Log

Aplicar función a variables con asimetría severa como *actual_amount_paid_sum* y *total_secs_sum*.

$$\log (1 + x)$$

Limpieza de Outliers

Aplicar técnicas de Winsorización en variables temporales y filtrar registros con inconsistencias extremas (ej. expiración menor a -365 días).

Reducción de Ruido

Eliminar un total de 11 variables redundantes (medias y máximos colineales de precios y reproducciones) para potenciar la interpretabilidad.

Conclusiones del Proyecto

- ✓ **Dominio Temporal:** Se confirmó mediante tres metodologías independientes que el bloque de variables temporales de membresía lidera la capacidad predictiva del churn.
- ✓ **Eficiencia Operativa:** La depuración por multicolinealidad simplificó el set de datos sin sacrificar precisión, ofreciendo un modelo robusto y altamente interpretable.
- ✓ **Sistemas de Alerta:** Las métricas de inactividad (ej. *days_since_last_log* > 60 días) permiten diseñar campañas de retención automatizadas y oportunas para KKBOX.